

Mạng nơ-ron sâu cho Hệ thống Nhận dạng Biển báo Giao thông: Phân tích về Mạng Biến đổi Không gian và các Phương pháp Tối ưu hóa Ngẫu nhiên

(Deep Neural Network for Traffic Sign Recognition Systems: An analysis of Spatial Transformers and Stochastic Optimization Methods)

Tác giả: Álvaro Arcos-García*, Juan A. Álvarez-García, Luis M. Soria-Morillo

Khoa Ngôn ngữ và Hệ thống Máy tính, Đại học Seville, 41012, Sevilla, Tây Ban Nha

Tóm tắt (Abstract)

Bài báo này trình bày một phương pháp Học sâu (Deep Learning) cho các hệ thống nhận dạng biển báo giao thông. Một số thí nghiệm phân loại được tiến hành trên các tập dữ liệu biển báo giao thông có sẵn công khai từ Đức và Bỉ bằng cách sử dụng một Mạng Nơ-ron Sâu (Deep Neural Network) bao gồm các lớp Tích chập (Convolutional layers) và Mạng Biến đổi Không gian (Spatial Transformer Networks). Các thử nghiệm này được xây dựng nhằm đo lường tác động của các yếu tố đa dạng với mục tiêu tối hậu là thiết kế một Mạng Nơ-ron Tích chập (CNN) có khả năng cải thiện mức độ tiên tiến (state-of-the-art) của tác vụ phân loại biển báo giao thông. Một mặt, các thuật toán tối ưu hóa hạ gradient ngẫu nhiên (stochastic gradient descent) thích ứng và không thích ứng khác nhau như SGD, SGD-Nesterov, RMSprop và Adam đã được đánh giá. Mặt khác, nhiều tổ hợp của Mạng Biến đổi Không gian đặt tại các vị trí khác biệt trong mạng nơ-ron chính cũng được phân tích. Mạng Nơ-ron Tích chập được đề xuất báo cáo đạt độ chính xác nhận dạng là 99.71% trong Tập dữ liệu Tiêu chuẩn Nhận dạng Biển báo Giao thông Đức (German Traffic Sign Recognition Benchmark), vượt trội so với các phương pháp state-of-the-art trước đây và đồng thời hiệu quả hơn về mặt yêu cầu bộ nhớ.

Từ khóa: học sâu (deep learning), biển báo giao thông, mạng biến đổi không gian (spatial transformer network), mạng nơ-ron tích chập (convolutional neural network)

1. Giới thiệu (Introduction)

Hệ thống nhận dạng biển báo giao thông (Traffic sign recognition systems - TSRS) là thành phần thiết yếu trong nhiều ứng dụng thực tế như lái xe tự động, giám sát giao thông, hỗ trợ và an toàn cho người lái, bảo trì mạng lưới đường bộ hoặc hiểu ngữ cảnh quan đô thị. Thông thường, một TSRS liên quan đến hai chủ đề có tính gắn kết là phát hiện biển báo giao thông (traffic sign detection - TSD) và nhận dạng biển báo giao thông (traffic sign recognition - TSR). Phần trước tập trung vào việc xác định vị trí của các mục tiêu trong hình ảnh, trong khi phần

sau thực hiện việc **phân loại chi tiết (fine-grained classification) để xác định loại của các mục tiêu** đã được phát hiện (De La Escalera et al., 1997).

Biển báo giao thông là một tài sản cơ bản trong mạng lưới đường bộ bởi mục đích của chúng là dễ dàng được người đi bộ và người lái xe nhận biết để cảnh báo và hướng dẫn họ trong cả thời gian ban ngày và ban đêm. Thực tế là **các biển báo được thiết kế để mang tính duy nhất, cứng cáp và có các đặc trưng để phân biệt như hình dạng đơn giản và màu sắc đồng nhất** ngụ ý rằng việc **phát hiện và nhận dạng chúng là một bài toán có ràng buộc (constrained problem)**. Mặc dù vậy, việc phát triển một TSRS thời gian thực mạnh mẽ vẫn là một nhiệm vụ đầy thách thức **do tính biến động của thế giới thực như thay đổi tỷ lệ (scale), góc nhìn xấu, nhòe do chuyển động (motion-blur), màu sắc phai mờ, bị che khuất (occlusions) hoặc điều kiện ánh sáng**. Thêm vào đó, có hơn 300 danh mục biển báo giao thông khác nhau được định nghĩa bởi Công ước Vienna về Giao thông Đường bộ (Ủy ban Kinh tế Châu Âu của Liên Hợp Quốc, 1968). Hiệp ước này đã được 63 quốc gia ký kết, mặc dù vẫn tồn tại những biến thể hình ảnh nhỏ của các chữ tượng hình trên biển báo giao thông giữa các quốc gia, điều này có thể dẫn đến những nhiệm vụ khắt khe đối với máy móc. Bất kỳ TSRS nào cũng phải xử lý tốt các vấn đề này.

Những **đóng góp chính của công trình này gồm 4 phần: (1) Một hệ thống nhận dạng biển báo giao thông state-of-the-art dựa trên Mạng Nơ-ron Tích chập (CNN)** bao gồm **Mạng Biến đổi Không gian (STN)** và vượt trội so với các công trình đã công bố trước đây liên quan đến **Benchmark Nhận dạng Biển báo Giao thông Đức (GTSRB)** (Stallkamp et al., 2011). (2) Chúng tôi cung cấp cái nhìn sâu sắc **về các khả năng của CNN được đề xuất cùng với tác động đến hiệu suất của các lớp biến đổi không gian (spatial transformer layers) bên trong mạng**. (3) Phân tích **tác động của các thuật toán tối ưu hóa hạ gradient khác nhau trên CNN được trình bày**. (4) Đánh giá **nhiều tập dữ liệu phân loại biển báo giao thông ở Châu Âu được cung cấp công khai thông qua CNN** này. Những đóng góp này dẫn đến các ứng dụng thực tiễn như xe tự lái hoặc tự động hóa việc kiểm kê và bảo trì hệ thống biển báo dọc vì CNN có thể thực hiện phân loại chi tiết sau khi biển báo giao thông được phát hiện. Hơn nữa, vì CNN vượt qua hệ thống thị giác của con người, thời gian suy luận (inference time) của nó khá thấp và có thể được triển khai như một dịch vụ độc lập, nó có thể được sử dụng trong các ứng dụng thời gian thực.

Phần còn lại của bài báo được tổ chức như sau. **Phần 2 đánh giá các công trình liên quan về hệ thống nhận dạng biển báo giao thông**. **Phần 3 mô tả các thí nghiệm được tiến hành để phân tích tác động của cả mạng biến đổi không gian và thuật toán tối ưu hóa ngẫu nhiên trên CNN** được đề xuất. Sau đó, **kết quả nhận dạng được hiển thị trong Phần 4**. Cuối cùng, **kết luận và các công việc tiếp theo được rút ra trong Phần 5**.

2. Các công trình liên quan (Related works)

Về mặt trình tự thời gian, các cách tiếp cận của những công trình đã công bố về hệ thống nhận dạng biển báo giao thông đã phát triển từ các phương pháp dựa trên màu sắc và hình dạng sang các phương pháp dựa trên học máy (machine learning). Trong thời gian gần đây, CNN đã thu hút sự chú ý trong nghiên cứu nhận dạng mẫu và thị giác máy tính, và đã được áp dụng rộng rãi cho cả việc phát hiện và nhận dạng đối tượng.

Các cách tiếp cận **dựa trên màu sắc** rất phổ biến. Các phương pháp này **sử dụng các không gian màu khác nhau để phân đoạn hình ảnh con đường như RGB (Escalera et al., 1997), HIS (Maldonado-Bascon et al., 2007) hoặc HSV (Shadeed et al., 2003)**, cùng nhiều không gian khác. **Phương pháp dựa trên hình dạng** là một hướng tiếp cận phổ biến khác cho việc nhận dạng và phát hiện biển báo giao thông. Thông tin đối xứng của các hình tròn, hình tam giác, hình vuông và hình bát giác được sử dụng trong (Loy & Barnes, 2004), một bộ dò tìm đối xứng xuyên tâm (radial symmetry detector) được đề xuất trong (Barnes et al., 2008), các phép biến đổi Hough được nghiên cứu trong (Barnes et al., 2010) và một hệ thống nhận dạng biển báo giao thông hình tròn được nghiên cứu trong (Kaplan Berkaya et al., 2016).

Một trong những vấn đề chính trước năm 2011 là sự thiếu hụt của một tập dữ liệu biển báo giao thông khả dụng công khai. **Tập dữ liệu Biển báo Giao thông Bỉ (BTSD) (Timofte et al., 2011), Benchmark Nhận dạng và Phát hiện Biển báo Giao thông Đức (GTSRB và GTSDb) (Stallkamp et al., 2011), và gần đây hơn, tập dữ liệu biển báo giao thông Croatia (rMASTIF) (Jurisic et al., 2015), Tập dữ liệu Biển báo Giao thông Ý (DITS) (Youssef et al., 2016) và Benchmark Tsinghua-Tencent 100K (Zhu et al., 2016)** đã giải quyết vấn đề này và thúc đẩy nghiên cứu trong lĩnh vực TSRS vì một số trong số chúng thường được sử dụng để đánh giá hiệu suất của các thuật toán thị giác máy tính cho việc phát hiện và nhận dạng biển báo giao thông. Mathias và cộng sự (2013) đề xuất phân loại chi tiết (fine grained classification) áp dụng các phương pháp khác nhau thông qua **một quy trình (pipeline) gồm 3 giai đoạn: trích xuất đặc trưng, giảm chiều dữ liệu và phân loại**. Trên GTSRB, họ đạt độ chính xác 98.53% khi kết hợp các giá trị độ xám của hình ảnh biển báo giao thông và các đặc trưng dựa trên Biểu đồ Tàn suất Gradient Định hướng (HOG), giảm chiều dữ liệu thông qua Phép chiếu Tuyến tính dựa trên Số nhân Láng giềng Gần nhất Lặp lại (INNLP) và phân loại bằng Phân loại Láng giềng Gần nhất Lặp lại (Timofte & Van Gool, 2015) (INNC). Mặc dù các bộ phân loại Máy Vector Hỗ trợ (SVM) (Salti et al., 2015), Rừng Ngẫu nhiên (Random Forests) (Zaklouta et al., 2011) và Láng giềng Gần nhất (Nearest Neighbours) (Gudigar et al., 2017) đã được sử dụng để nhận dạng hình ảnh biển báo giao thông, Mạng Nơ-ron Tích chập (Lecun et al., 1998), còn được biết đến là ConvNets hay CNNs, đã cho thấy độ chính xác phân loại đặc biệt cao trong cuộc thi. **Ciresan và cộng sự (2012) đã chiến thắng cuộc thi GTSRB (Stallkamp et al., 2012) với độ chính xác 99.46%** nhờ vào một hội đồng (committee) **gồm 25 CNN bằng cách sử dụng tăng**

cường dữ liệu (data augmentation) và làm nhiễu (jittering). Sermanet & LeCun (2011) sử dụng CNN đa tỷ lệ (multi-scale) đạt độ chính xác 98.31%, xếp vị trí thứ hai trong thử thách GTSRB. Sau đó, Jin và cộng sự (2014) đề xuất một phương pháp hạ gradient ngẫu nhiên với hàm mất mát hinge (hinge loss stochastic gradient descent) để huấn luyện một tổ hợp (ensemble) gồm 20 CNNs mang lại độ chính xác 99.65% và cung cấp sự hội tụ nhanh hơn, ổn định hơn so với các công trình trước. Tuy nhiên, các cách tiếp cận này vẫn có thể được cải thiện bằng cách tránh sử dụng tăng cường dữ liệu thủ công (hand-crafted data augmentation) và tránh việc áp dụng nhiều CNN trong một tổ hợp hay hội đồng, bởi lý do là nó thường dẫn đến chi phí tính toán và bộ nhớ cao hơn.

3. Phương pháp luận (Methodology)

Trong công trình này, chúng tôi đề xuất một hệ thống nhận dạng biển báo giao thông thực hiện phân loại chi tiết cho các hình ảnh biển báo giao thông thông qua một CNN mà các khối chính là các module tích chập và module biến đổi không gian. Để tìm ra một CNN chính xác và hiệu quả cho mục đích này, trước tiên chúng tôi nghiên cứu và thảo luận về tác động của việc sử dụng nhiều STN và thứ hai là kết quả khi áp dụng các phương pháp tối ưu hóa hạ gradient ngẫu nhiên khác nhau.

3.1. Tập dữ liệu và tiền xử lý dữ liệu (Dataset and data pre-processing)

Nhiều tập dữ liệu biển báo giao thông công khai đã được thu thập ở các quốc gia như Hoa Kỳ (Mogelmose et al., 2012), Bỉ (Timofte et al., 2011), Đức (Stallkamp et al., 2011), Croatia (Jurisic et al., 2015), Ý (Youssef et al., 2016), Thụy Điển (Larsson & Felsberg, 2011) và Trung Quốc (Zhu et al., 2016). Vì GTSRB (Stallkamp et al., 2011) được sử dụng nhiều nhất để so sánh các phương pháp nhận dạng biển báo giao thông, chúng tôi tập trung cả hai thí nghiệm về tính hiệu quả của mạng biến đổi không gian và tối ưu hóa hàm chi phí trên tập dữ liệu này. Tập dữ liệu nhận dạng biển báo giao thông Đức chứa các mẫu biển báo giao thông với các độ phân giải khác nhau được trích xuất từ các chuỗi video 1 giây. Chúng thuộc về 1 trong 43 lớp tồn tại. Tập huấn luyện (Training set) có 39,209 hình ảnh và tập kiểm chứng (validation set) bao gồm 12,630 hình ảnh được sử dụng để đo lường hiệu suất của các thuật toán trong GTSRB. Các mẫu biển báo giao thông là ảnh RGB thô và có kích thước thay đổi từ 15x15 đến 250x250 pixel. Trong giai đoạn tiền xử lý, tất cả chúng đều được giảm mẫu (down-sampled) hoặc tăng mẫu (up-sampled) về 48x48 pixel và cả chuẩn hóa toàn cục (global normalisation) lẫn chuẩn hóa độ tương phản cục bộ với hạt nhân Gaussians (local contrast normalisation with Gaussians kernels) (Jarrett et al., 2009) được tính toán nhằm mục đích căn giữa mỗi hình ảnh đầu vào quanh giá trị trung bình của nó cũng như tăng cường các cạnh (Hình 1).

3.2. Kiến trúc Mạng Nơ-ron Tích chập (Convolutional Neural Network architecture)

Lấy cảm hứng từ cách tiếp cận của Cireşan và cộng sự (2012), phương pháp được đề xuất để nhận dạng biển báo giao thông **là một CNN kết hợp nhiều lớp tích chập, mạng biến đổi không gian (Jaderberg et al., 2015), ReLU (Nair & Hinton, 2010), chuẩn hóa độ tương phản cục bộ (Jarrett et al., 2009) và max-pooling (Scherer et al., 2010).** Nó hoạt động như một bộ trích xuất đặc trưng (feature extractor) **ánh xạ thông tin pixel thô của hình ảnh đầu vào thành một tensor để được phân loại bởi hai lớp kết nối đầy đủ (fully connected layers).** Các lớp biến đổi không gian được sử dụng để **thực hiện các phép biến đổi hình học ngoại hiện (explicit geometric transformations) trên các bản đồ đặc trưng (feature maps)** nhằm tập trung vào đối tượng cần học, loại bỏ dần nền và nhiễu hình học. **Tất cả các tham số biến đổi được sử dụng trong mỗi lớp này được tối ưu hóa cùng nhau thông qua việc cực tiểu hóa lỗi phân loại sai trên tập huấn luyện GTSRB.**

Mạng Biến đổi Không gian (Spatial Transformer Networks) nhằm mục đích thực hiện một phép biến đổi hình học trên một bản đồ đầu vào sao cho cung cấp cho CNN khả năng bất biến không gian (spatially invariant) đối với dữ liệu đầu vào theo cách tính toán hiệu quả. Nhờ các phép biến đổi như vậy, không cần thêm việc giám sát huấn luyện, tăng cường dữ liệu thủ công (ví dụ: xoay, dịch chuyển, thay đổi tỷ lệ, kéo nghiêng, cắt xén) hoặc các kỹ thuật chuẩn hóa tập dữ liệu. Module có khả năng vi phân này có thể được chèn vào các kiến trúc tích chập hiện có bởi vì các tham số của phép biến đổi áp dụng lên bản đồ đặc trưng được học thông qua thuật toán lan truyền ngược (backpropagation). **Mạng biến đổi không gian bao gồm 3 phần tử: mạng định vị (localisation network), bộ tạo lưới (grid generator) và bộ lấy mẫu (sampler)** (Hình 2).

Mạng định vị $f_{loc}()$ lấy bản đồ đặc trưng đầu vào $U \in \mathbb{R}^{H \times W \times C}$, trong đó H , W và C lần lượt là chiều cao, chiều rộng và số kênh, và xuất ra các tham số θ của phép biến đổi T_θ sẽ được áp dụng cho bản đồ đặc trưng $\theta = f_{loc}(U)$. Kích thước của θ phụ thuộc vào loại biến đổi T_θ đang được tham số hóa, trong mạng đề xuất của chúng tôi nó có 6 chiều (6-dimensional) như là kết quả của việc thực hiện phép biến đổi affine 2D A_θ cho phép dịch chuyển, cắt xén, xoay, thay đổi tỷ lệ và kéo nghiêng. Mạng định vị có thể bao gồm bất kỳ số lượng lớp tích chập và lớp kết nối đầy đủ nào và phải có ít nhất một lớp hồi quy (regression layer) cuối cùng để tạo ra các tham số biến đổi θ . Các tham số này được bộ tạo lưới sử dụng để tạo ra một lưới lấy mẫu (sampling grid), là một tập hợp các điểm mà tại đó bản đồ đầu vào phải được lấy mẫu để có được đầu ra đã biến đổi mong muốn. Cuối cùng, bộ lấy mẫu sử dụng lưới lấy mẫu và bản đồ đặc trưng đầu vào U để thực hiện lấy mẫu song tuyến tính (bilinear sampling) tạo ra bản đồ đặc trưng đầu ra đã biến đổi $V \in \mathbb{R}^{H' \times W' \times C}$, nơi H' , W' là chiều cao và chiều rộng của lưới lấy mẫu.

Đối với tọa độ nguồn trong bản đồ đặc trưng đầu vào (x_i^s, y_i^s) và một ma trận biến đổi affine 2D được học A_θ , tọa độ đích của lưới đều đặn trong bản đồ đặc trưng đầu ra (x_i^t, y_i^t) được cho như sau (Pt. 1):

$$\begin{pmatrix} x_i^s \\ y_i^s \end{pmatrix} = A_\theta \begin{pmatrix} x_i^t \\ y_i^t \\ 1 \end{pmatrix} = \begin{bmatrix} \theta_{11} & \theta_{12} & \theta_{13} \\ \theta_{21} & \theta_{22} & \theta_{23} \end{bmatrix} \begin{pmatrix} x_i^t \\ y_i^t \\ 1 \end{pmatrix} \quad (1)$$

Về vấn đề nhận dạng biến báo giao thông, mạng biến đổi không gian học cách tập trung vào biến báo giao thông bằng việc loại bỏ dần nhiều hình học và nền để chỉ các vùng thú vị của đầu vào được chuyển tiếp tới các lớp tiếp theo của mạng (Hình 3). Theo sự hiểu biết của chúng tôi, chưa có công trình phản biện đồng cấp (peer review) nào được công bố về việc đưa đơn vị biến đổi không gian vào một CNN cho tác vụ nhận dạng biến báo giao thông.

Để đo lường hiệu suất của các lớp biến đổi không gian cho nhận dạng biến báo giao thông, chúng tôi thiết lập kiến trúc CNN chính được hiển thị trong Bảng 1 mà không chứa bất kỳ STN nào. Bước trượt (stride) của lớp tích chập được đặt là 1 để nhường toàn bộ tính toán giảm mẫu không gian (spatial down-sampling) cho các lớp max-pooling, và zero padding được đặt thành 2. Về các lớp max-pooling, stride của chúng được đặt là 2 và zero padding là 0. Bản đồ đặc trưng đầu vào và đầu ra của các lớp tích chập, cũng như kích thước hạt nhân (kernel sizes), đều được cố định¹.

Do khả năng kết hợp lên đến 3 STN ở các phần khác nhau của mạng, một số kiến trúc mạng đã được thiết lập để đo lường ảnh hưởng của chúng đến kết quả cuối cùng. Lưu ý rằng việc đưa vào nhiều hơn ba STN không được phân tích vì kích thước bản đồ đặc trưng đầu ra của các lớp mạng tiếp theo không thể giảm thêm nữa. Dần dần, các module biến đổi không gian được thêm vào trước các lớp tích chập của mạng chính. Mạng định vị của ba lớp biến đổi không gian được xây dựng bằng một lớp max-pooling theo sau là hai khối gồm tích chập, ReLU và max-pooling, và cuối cùng là hai lớp kết nối đầy đủ được nối bởi một lớp ReLU. Đầu ra của lớp kết nối đầy đủ cuối cùng bao gồm sáu nơ-ron tương ứng với các tham số của ma trận biến đổi affine. Kiến trúc chi tiết của các mạng định vị được vẽ trong Bảng 2. Giống như cấu hình các lớp tích chập, kích thước hạt nhân và số lượng bản đồ đặc trưng đầu vào, đầu ra là không đổi.

Tổng cộng, có tám kiến trúc CNN khác nhau như là kết quả của các tổ hợp có thể được mô tả. Để biểu thị các cấu hình như vậy, một mặt, c đề cập đến một khối tích chập bao gồm các lớp tích chập, ReLU, max-pooling và chuẩn hóa độ tương phản cục bộ. Mặt khác, s_i chỉ ra cấu hình thứ $i - th$ của một module biến đổi không gian. Ví dụ, một mạng chỉ có một bộ biến đổi không gian ở phần đầu được biểu thị là s_1-c-c . Lưu ý rằng s_1 chỉ có thể được đặt trước lớp tích chập đầu tiên, s_2 đi trước lớp tích chập thứ hai và s_3 đứng trước module tích chập thứ ba.

(Bảng 1: Kiến trúc CNN chính không có module mạng biến đổi không gian. - Dịch chi tiết các trường trong ảnh nếu cần, nhưng định dạng cột được giữ nguyên cấu trúc khái niệm)

Bảng 1: Kiến trúc CNN chính không có các module biến đổi không gian

Layer	Type	# Maps & neurons	Kernel
0	Input	3 m. of 48x48 n.	
1	Convolutional	200 m. of 46x46 n.	7x7
2	ReLU	200 m. of 46x46 n.	
3	Max-Pooling	200 m. of 23x23 n.	2x2
4	Local Contrast Norm.	200 m. of 23x23 n.	
5	Convolutional	250 m. of 24x24 n.	4x4
6	ReLU	250 m. of 24x24 n.	
7	Max-Pooling	250 m. of 12x12 n.	2x2
8	Local Contrast Norm.	250 m. of 12x12 n.	
9	Convolutional	350 m. of 13x13 n.	4x4
10	ReLU	350 m. of 13x13 n.	
11	Max-Pooling	350 m. of 6x6 n.	2x2
12	Local Contrast Norm.	350 m. of 6x6 n.	
13	Fully connected	400 neurons	1x1
14	ReLU	400 neurons	
15	Fully connected	43 neurons	1x1
16	Soft-max	43 neurons	

Table 1: Main CNN architecture without spatial transformer modules.

Bảng 2: Chi tiết mạng định vị (Localisation network) của các spatial transformers sử dụng trong CNN cơ bản. Kích thước kernel của các lớp convolutional được đặt là 5x5 và các lớp max-pooling là 2x2. Chú thích hiển thị trong bảng được đơn giản hóa, ví dụ, 3 of 48x48 nghĩa là 3 bản đồ đặc trưng kích thước mỗi cái là 48x48 nơ-ron.

Layer/Type	Loc. net of ST 1	Loc. net of ST 2	Loc. net of ST 3
0/Input	3 of 48x48	200 of 23x23	250 of 12x12
1/Max-Pool	3 of 24x24	200 of 11x11	250 of 6x6
2/Conv	250 of 24x24	150 of 11x11	150 of 6x6
3/ReLU	250 of 24x24	150 of 11x11	150 of 6x6
4/Max-Pool	250 of 12x12	150 of 5x5	150 of 3x3
5/Conv	250 of 12x12	200 of 5x5	200 of 3x3
6/ReLU	250 of 12x12	200 of 5x5	200 of 3x3
7/Max-Pool	250 of 6x6	200 of 2x2	200 of 1x1
8/Fc	250 neurons	300 neurons	300 neurons
9/ReLU	250 neurons	300 neurons	300 neurons
10/Fc	6 neurons	6 neurons	6 neurons

¹ Mã nguồn (Source-code) sẽ được công khai.

3.3. Thuật toán Tối ưu hóa Hạ Gradient Ngẫu nhiên (Stochastic Gradient Descent Optimization algorithms)

Tối ưu hóa là quá trình tìm kiếm tập các tham số w làm cực tiểu hóa hàm mất mát (loss function) L . Hàm mất mát L định lượng chất lượng của một tập tham số w cụ thể dựa trên mức độ khớp giữa các điểm số được suy luận (inferred scores) với các nhãn thực tế (ground truth labels) trong dữ liệu huấn luyện. Trong công trình này, lớp cuối cùng của các CNN được đề xuất là một bộ phân loại softmax sử dụng hàm mất mát cross-entropy (Pt. 2) trong đó i liệt kê các lớp khác nhau, y là phân phối xác suất dự đoán và y' là phân phối thực được biểu diễn dưới dạng vector one-hot. Hàm softmax (Pt. 3) được sử dụng để tính y . Nó lấy một vector K -chiều gồm các điểm số thực tùy ý z và nén nó thành một vector K -chiều $f(z)$ chứa các giá trị trong khoảng $(0,1]$ với tổng bằng 1, trong đó j đại diện cho phần tử thứ j -th của vector f .

$$H_{y'}(y) = - \sum_i y'_i \log(y_i)$$

$$y_i \in (0,1): \sum_i y_i = 1 \forall i(2)$$

$$f_j(z) = \frac{e^{z_j}}{\sum_{k=1}^K e^{z_k}} (3)$$

Hạ Gradient (Gradient descent) là thuật toán phổ biến và lâu đời nhất để tối ưu hóa hàm mất mát của mạng nơ-ron. Một cách lặp lại, nó tính toán gradient của hàm mục tiêu L liên quan đến các tham số mô hình w và cập nhật chúng. Một trong các biến thể của nó là mini-batch gradient descent (hạ gradient theo lô nhỏ) có thể được viết như sau:

$$w_{k+1} = w_k - \eta_k \nabla L(w_k) (4)$$

Nó tính toán gradient $\nabla L(w_k) := \nabla L(w_k; x_k^{(i:i+n)}; y_k^{(i:i+n)})$ của hàm mất mát L và thực hiện một bản cập nhật cho mỗi mini-batch gồm n ví dụ huấn luyện $x^{(i)}$ và nhãn $y^{(i)}$, đại diện bởi η là learning rate (tốc độ học).

Để tăng tốc quá trình huấn luyện, một số kỹ thuật như Phương pháp Gradient Tăng tốc của Nesterov (NAG) (Nesterov, 1983) và Phương pháp heavy-ball của Polyak (HB) (Polyak, 1964) đã được sử dụng rộng rãi. Chúng có thể được phân loại là các phương pháp động lượng ngẫu nhiên (stochastic momentum methods).

Các phương pháp tối ưu hóa thích ứng (Adaptive optimization methods) là một nhóm thuật toán hạ gradient khác. So với các phương pháp không thích ứng, chúng thực hiện tối ưu hóa cục bộ (local optimization) bằng cách chọn một thước đo khoảng cách cục bộ được xây dựng từ lịch sử của các lần lặp lại $w_1, \dots, w_k$. Các ví dụ nằm trong danh mục này bao gồm thuật toán Adaptive

Gradient (AdaGrad) (Duchi et al., 2011), Root Mean Square Propagation (RMSprop) (Tieleman & Hinton, 2012) và Adaptive Moment Estimation (Adam) (Kingma & Ba, 2015).

Trong bài báo này, chúng tôi so sánh tính hiệu quả của bốn thuật toán tối ưu hóa mini-batch gradient descent được áp dụng cho các CNN đề xuất trong Phần 3.2: Stochastic Gradient Descent (SGD) không có động lượng (momentum) (Qian, 1999), SGD với Nesterov's accelerated gradient, RMSprop và Adam. Về việc tinh chỉnh siêu tham số (hyper parameter tuning), một số mạng đã được huấn luyện trong một vài epoch để tìm ra giá trị tốc độ học ban đầu (initial learning rate) thích hợp giúp đạt được sự hội tụ của mô hình. Chúng tôi quan sát thấy rằng tốc độ học cao như 0.01 không hoạt động tốt trong các trường hợp của RMSprop và Adam, đạt điểm số độ chính xác thấp. Lý do chính có thể là không giống như SGD, nơi mà tốc độ học được cố định và có thể tùy chọn tuân theo một lịch trình giảm dần (annealing schedule), RMSprop và Adam tính toán tốc độ học thích ứng cho từng tham số của mô hình dựa trên lịch sử lặp lại. Do đó, một tốc độ học thấp hơn được thiết lập cho các phương pháp này để tránh giá trị loss bị mắc kẹt tại các điểm xấu trong bối cảnh tối ưu hóa. Các tham số ban đầu của các thuật toán này được hiển thị trong Bảng 3.

Bảng 3: Các tham số cấu hình của các thuật toán tối ưu hóa hạ gradient ngẫu nhiên.

SGD w/o momentum	SGD with Nesterov
Momentum = 0 Weight decay = 0 Learning rate = $1e-2$	Momentum = 0.9 Weight decay = $1e-4$ Nesterov Learning rate = $1e-3$
RMSprop	Adam
$\alpha=0.99$ $\epsilon=1e-8$ Weight decay = 0 Learning rate = $1e-5$	$\beta_1 = 0.9$ $\beta_2 = 0.999$ $\epsilon = 1e-8$ Weight decay = 0 Learning rate = $1e-4$

4. Kết quả (Results)

Sau khi mô tả các kiến trúc CNN và bộ tối ưu hóa hàm mất mát, 32 thử nghiệm đã được chạy trên một máy tính được cấu trúc với CPU Intel Core i7-6700k, RAM 16 GB và một GPU rời Nvidia Geforce GTX 1070 có 1920 lõi CUDA cùng 8 GB RAM, sử dụng framework tính toán khoa học Torch (Collobert et al., 2011) và một bản triển khai mạng biến đổi không gian cho Torch (Oquab, 2017) làm các công cụ phát triển. Mục đích là để tìm ra những vị trí tốt nhất để

thêm các STN trong CNN đồng thời với bộ tối ưu hóa hạ gradient ngẫu nhiên tốt nhất. Với kích thước mini-batch là 50, mỗi thử nghiệm là một quá trình gồm hai giai đoạn: huấn luyện mạng nơ-ron với tập huấn luyện GTSRB và sau đó kiểm tra (test) nó bằng tập kiểm chứng GTSRB trong 15 epoch. Kết quả được vẽ ở Bảng 4 chỉ ra tỷ lệ phần trăm độ chính xác cao nhất đạt được bởi mỗi mô hình CNN trên tập kiểm chứng. Cấu hình tốt nhất được tìm thấy chứa ba module mạng biến đổi không gian ($s_1-c-s_2-c-s_3-c$) và giá trị mất mát được tính toán được tối ưu thông qua thuật toán SGD không có động lượng. Mặt khác, kết quả tồi nhất đạt được bởi cấu hình CNN không bao gồm bất kỳ bộ biến đổi không gian nào ($c-c-c$) bất kể bộ tối ưu hóa, tiếp theo là CNN có bộ biến đổi không gian nằm ngay trước lớp tích chập cuối cùng ($c-c-s_3-c$). Đáng chú ý là cấu hình chiến thắng nhân đôi số lượng tham số mô hình so với CNN tệ nhất. Hệ quả là, đối với thuật toán tối ưu hóa SGD không có momentum, thời gian huấn luyện mỗi epoch của CNN với ba bộ biến đổi không gian là 355.05 ± 0.8 giây trong khi CNN không có bộ biến đổi không gian tốn 212.12 ± 0.1 giây. Xem xét các kết quả này và rằng các giải pháp tìm thấy bởi các phương pháp thích ứng thường tổng quát hóa (generalise) kém hơn so với SGD (Wilson et al., 2017), từ nay, chúng tôi chọn CNN $s_1-c-s_2-c-s_3-c$ (Hình 4) cùng với thuật toán SGD không có momentum làm phương pháp đề xuất của mình cho phân loại biển báo giao thông, với thời gian xử lý để huấn luyện và kiểm tra một ví dụ lần lượt là 11.18 ± 0.02 và 4.28 ± 0.02 ms. Một so sánh về độ chính xác và các giá trị hàm mất mát được tính toán cho mỗi thuật toán tối ưu hóa trên tập kiểm chứng được hiển thị trong Hình 5.

Bảng 4: Tỷ lệ độ chính xác nhận dạng đạt được bởi các cấu hình CNN được mô tả trong Phần 3.2 sử dụng các bộ tối ưu hàm mất mát khác nhau: SGD không có momentum (SGD), SGD với gradient tăng tốc Nesterov (SGD-N), Root Mean Square Propagation (RMSprop) và Adaptive Moment Estimation (Adam). c chỉ khối convolutional và s chỉ module spatial transformer. Các thí nghiệm được chạy trong 15 epochs.

CNN/Optimizer	SGD	SGD-N	RMSprop	Adam	# Parameters
$c-c-c$	98.31	98.33	98.66	98.81	7,303,883
$s_1-c-c-c$	99.09	99.15	99.37	99.20	11,137,389
$c-s_2-c-c$	99.22	99.13	99.28	99.15	9,046,339
$c-c-s_3-c$	99.02	99.04	99.11	99.39	9,053,839
s_1-c-s_2-c-c	99.31	99.30	99.38	99.23	12,879,845
$s_1-c-c-s_3-c$	99.21	99.25	99.32	99.32	12,887,345
$c-s_2-c-s_3-c$	99.34	99.23	99.45	99.28	10,796,295
$s_1-c-s_2-c-s_3-c$	99.49	99.43	99.40	99.42	14,629,801

Các phần tiểu mục sau đây mô tả tập dữ liệu biển báo giao thông Đức và Bỉ cùng với kết quả phân loại đạt được. Cấu trúc của mỗi tập dữ liệu được vẽ trong Bảng 5 kèm theo kết quả nhận dạng tổng thể. Lưu ý rằng các tập dữ liệu này mất cân bằng dữ liệu cực cao như có thể thấy ở Hình 6.

4.1. Kết quả trên tập dữ liệu GTSRB

Tập dữ liệu GTSRB đã được giới thiệu trong Phần 3.1. Mạng CNN đề xuất của chúng tôi với ba lớp mạng biến đổi không gian và SGD không có momentum làm bộ tối ưu hóa hàm mất mát đạt độ chính xác 99.71% tại epoch thứ 21 (nhiều hơn 6 epoch so với thí nghiệm trước). Tại thời điểm viết bài báo này, phương pháp của chúng tôi xếp hạng top-1 trong GTSRB, vượt trội so với các cách tiếp cận đã được công bố trước đó (Bảng 6). Thêm vào đó, tổng số lượng tham số được học bởi CNN này là 14,629,801, ít hơn rất nhiều so với các CNN khác được đề xuất cho các hệ thống nhận dạng biển báo giao thông (Bảng 7), mang lại lợi thế này đối với việc tiêu thụ bộ nhớ thấp hơn, chi phí tính toán thấp hơn và một pipeline đơn giản hơn.

Bảng 5: Các tập dữ liệu phân loại biển báo giao thông châu Âu cùng với các kết quả nhận dạng precision, recall và f1-score.

Dataset	Training images	Testing images	Classes
Germany	39,209	12,630	43
Belgium	4,533	2,562	62
	Precision (%)	Recall (%)	F1 score (%)
Germany	99.71	99.71	99.71
Belgium	98.95	98.87	98.86

Bảng 6: Tỷ lệ độ chính xác nhận dạng của các phương pháp khác nhau trên GTSRB.

Paper	Method	Accuracy (%)
Ours	Single CNN with 3 STNs	99.71
Jin et al. (2014)	HLSGD (20 CNNs ensemble)	99.65
Cireřan et al. (2012)	MCDNN (25 CNNs committee)	99.46
Yu et al. (2016)	GDBM	99.34
Stallkamp et al. (2011)	Human performance (best)	99.22
Jurisić et al. (2015)	OneCNN	99.11 $\pm$ 0.10

Bảng 7: Tham số có thể huấn luyện của CNN đề xuất so với các phương pháp state-of-the-art trước đó.

Paper	Data augment. or jittering	# trainable parameters	# ConvNets
Ours	No	14,629,801	1
Jin et al. (2014)	Yes	~ 23 millions	20 (ensemble)
Cireřan et al. (2012)	Yes	~ 90 millions	25 (committee)

4.2. Kết quả trên tập dữ liệu BTSC

Tập dữ liệu phân loại biển báo giao thông Bỉ (BTSC) (Mathias et al., 2013) có 4,533 hình ảnh huấn luyện và 2,562 hình ảnh kiểm chứng được chia thành 62 loại biển báo giao thông. So với tập dữ liệu GTSRB, tập này có các chữ tượng hình biển báo giao thông, điều kiện ánh sáng, sự che khuất, độ phân giải hình ảnh và nhiều yếu tố khác khác biệt. Hơn nữa, nó chứa các danh mục phân cụm các loại biển báo giao thông khác nhau (ví dụ: biển giới hạn tốc độ 50 và biển giới hạn tốc độ 70) làm tăng độ khó của nhiệm vụ nhận dạng. Bằng việc sử dụng bộ tối ưu hóa mất mát SGD không có momentum và CNN với ba lớp biến đổi không gian, mô hình đạt độ chính xác 98.87% tại epoch thứ 13 (Bảng 8).

Bảng 8: Tỷ lệ độ chính xác nhận dạng của các phương pháp khác nhau trên BTSC.

Paper	Method	Accuracy (%)
Yu et al. (2016)	GDBM	98.92
Ours	Single CNN with 3 STNs	98.87
Jurisic et al. (2015)	OneCNN	98.17 ± 0.22
Mathias et al. (2013)	INNLP+SRC(PI)	97.83

5. Kết luận và công việc tương lai (Conclusions and future work)

Trong bài báo này, một phương pháp để nhận dạng chi tiết tự động các biển báo giao thông đã được trình bày. Quá trình phân loại được thực hiện bằng việc sử dụng một mạng CNN duy nhất đan xen giữa các module tích chập và biến đổi không gian. Để tìm ra kiến trúc CNN tốt nhất, một số thí nghiệm thực nghiệm được tiến hành nhằm điều tra tác động của cấu hình nhiều mạng biến đổi không gian bên trong CNN, cùng với hiệu quả của bốn thuật toán tối ưu hóa hạ gradient ngẫu nhiên. Mô hình CNN vượt trội hơn các phương pháp state-of-the-art trước đây khi đạt tỷ lệ chính xác nhận dạng 99.71% trong GTSRB, hiện xếp hạng vị trí thứ 1 (top-1 rank). Hơn thế nữa, cách tiếp cận được đề xuất của chúng tôi tránh được sự cần thiết của việc tăng cường dữ liệu thủ công và làm nhiễu (jittering) từng được sử dụng ở các công trình trước (Cireřan et al., 2012; Sermanet & LeCun, 2011; Jin et al., 2014). Thêm vào đó, nó đòi hỏi ít bộ nhớ hơn và mạng có ít tham số để học hơn so với các phương pháp hiện tại vì chúng tôi tránh sử dụng kết hợp nhiều mạng CNN theo một dạng hội đồng (committee) hoặc tổ hợp (ensemble).

Mặc dù phương pháp của chúng tôi xếp hạng ở các vị trí hàng đầu trên các tập dữ liệu của Đức và Bỉ, có một vài tập dữ liệu nhận dạng biển báo giao thông công khai phát hành gần đây mà phương pháp này vẫn chưa được kiểm tra bởi do chúng không phổ biến và lâu đời như các tập dữ liệu trước đó. Tuy nhiên, theo hiểu biết của chúng tôi, không có bài báo khoa học nào phân tích việc sử dụng nhiều STN và so sánh các bộ tối ưu hóa hạ gradient ngẫu nhiên trong lĩnh vực bài toán phân loại biển báo giao thông. Những thí nghiệm này và kết quả của chúng có thể giúp các nhà nghiên cứu khác áp dụng vào các tập dữ liệu mới này.

Công việc tương lai nên nghiên cứu cách xây dựng một mạng nơ-ron sâu duy nhất có khả năng cung cấp độ chính xác nhận dạng biển báo giao thông tốt bậc nhất ở mọi quốc gia nơi mà các chữ tượng hình biển báo giao thông khá tương đồng, đó là trường hợp của khu vực Châu Âu, mà không cần phải có một tập dữ liệu cụ thể cho từng quốc gia này. Cuối cùng, chúng tôi khuyến khích các nhà nghiên cứu và các công ty xây dựng các bộ phân loại biển báo giao thông có tính bền bỉ (robust) trước các ví dụ đối kháng (adversarial examples) vì nó đặt ra những lo ngại về bảo mật có thể gây ảnh hưởng tiêu cực, ví dụ như đối với xe tự lái, và hệ quả là đến sự an toàn của con người.